

PROYECTO FINAL DE LA E.E. APRENDIZAJE MÁQUINA
INGENIERÍA DE CIBERSEGURIDAD E INFRAESTRUCTURA DE CÓMPUTO
DOCENTE: DAVID MARTÍNEZ GALICIA
UNIVERSIDA VERACRUZANA

I. Descripción

El proyecto consiste en aplicar un flujo completo de aprendizaje supervisado sobre un conjunto de datos de ciberseguridad. Cada equipo debe seleccionar libremente un conjunto de datos real y definir una tarea de clasificación o regresión, justificando su relevancia. El trabajo debe cubrir todas las etapas clave del modelado.

Para ello, se deberá realizar un **análisis exploratorio** que incluya la estructura del conjunto, tipos de datos, valores faltantes, distribución de la variable objetivo (si aplica) y al menos dos visualizaciones relevantes, con análisis sobre desbalanceo o atípicos. A continuación, se aplicará el **preprocesamiento** necesario: codificación de variables categóricas, escalado de numéricas y partición entrenamiento/prueba (opcionalmente, selección o transformación de atributos, explicando el motivo). Cada equipo elegirá dos modelos diferentes y los entrenará con los datos de **entrenamiento**. La **evaluación** sobre el conjunto de prueba usará las métricas estándar:

- Clasificación: exactitud, precisión, sensibilidad, matriz de confusión.
- Regresión: MSE, RMSE, MAE, R^2 .

Además, se aplicará **validación** cruzada para obtener estimaciones robustas, reportando media y desviación estándar de la métrica principal. Finalmente, se compararán ambos modelos mediante una tabla con los **resultados** de prueba y validación cruzada, concluyendo cuál ofrece mejor desempeño y estabilidad. El proyecto cierra con **conclusiones** que incluyan el hallazgo principal, limitaciones y mejoras concretas para trabajo futuro.

2. Redacción del reporte

El reporte se entregará en formato PDF y debe redactarse como un documento académico. La estructura sugerida es la siguiente, pero puede adaptarse manteniendo la secuencia lógica.

- a. **Portada.** La primera página incluirá el título del proyecto, los nombres de los integrantes, la asignatura y la fecha.
- b. **Resumen.** Redacción de aproximadamente 150 palabras que sintetice el conjunto de datos, la tarea, los modelos utilizados y el resultado principal.

- c. **Introducción.** Se presentará el problema de ciberseguridad abordado y se justificará la tarea de aprendizaje supervisado elegida.
- d. **Análisis exploratorio (EDA).** Esta sección debe guiar al lector a través de los hallazgos. Se comentará la estructura y tipos de datos, el porcentaje de valores faltantes, y la distribución de la variable objetivo. Hacer uso de gráficos.
- e. **Preprocesamiento.** Se explicarán en orden los pasos aplicados: codificación de categóricas (indicando el método), escalado de numéricas (con justificación) y partición entrenamiento/prueba (especificando proporciones y si se usó estratificación). Si se realizó selección o transformación de atributos, se describirá el procedimiento y su motivación.
- f. **Entrenamiento y evaluación.** Se presentarán los dos modelos elegidos, con una breve fundamentación de su idoneidad y los hiperparámetros utilizados. Luego se mostrarán los resultados de la evaluación sobre el conjunto de prueba. Cada métrica se interpretará en el contexto del problema.
- g. **Comparación de modelos.** Se indicará el tipo de validación cruzada empleada y el número de particiones. Se reportará la media y la desviación estándar de la métrica principal. La discusión debe ir más allá de señalar un ganador: si hay compromiso entre rendimiento y simplicidad, o si un modelo es más robusto.
- h. **Conclusiones y trabajo futuro.** Se enunciará el hallazgo principal del proyecto. Se reconocerá una limitación concreta del análisis. Finalmente, se propondrán al menos mejoras concretas para trabajos posteriores.
- i. **Referencias.** Se incluirán las fuentes citadas (dataset, artículos, etc.) en formato IEEE. Incluir al menos 10.

3. Rúbrica de evaluación

Criterio	4 – Excelente	3 – Bueno	2 – Suficiente	1 – Insuficiente
1. Introducción	Se describe el conjunto de datos. La tarea de clasificación o regresión está bien definida y su relevancia para la ciberseguridad está sólidamente justificada.	Conjunto de datos descrito de forma aceptable. La tarea se define, pero la justificación es breve o poco específica.	El conjunto se menciona de manera vaga. La tarea es confusa o no se justifica.	No se presenta el conjunto ni se define la tarea.
2. Análisis exploratorio	Incluye estructura, tipos de datos, porcentaje de valores faltantes, distribución de la variable objetivo y visualizaciones relevantes. Se comenta el desbalanceo o presencia de atípicos con interpretación clara.	Cubre la mayoría de los elementos, pero falta una visualización o el comentario es muy general.	Solo presenta una tabla básica y un gráfico, sin interpretación.	No hay EDA o es irrelevante para el problema.
3. Preprocesamiento	Explica en orden y con detalle la codificación de categóricas, el escalado de numéricas y la partición entrenamiento/prueba. Si hubo selección o transformación de atributos, se describe el motivo.	Explica la mayoría de los pasos, pero omite algún elemento (por ejemplo, no justifica el escalado).	Solo menciona la partición y uno de los otros pasos, sin profundizar.	No describe el preprocesamiento o los pasos son incorrectos.
4. Entrenamiento y evaluación	Presenta dos modelos elegidos, justifica su elección e indica los hiperparámetros usados. Cada métrica se interpreta en el contexto del problema.	Presenta los modelos y las métricas, pero falta una métrica o la matriz de confusión. La interpretación es superficial.	Solo da los resultados numéricos sin interpretación o faltan métricas esenciales (ej. solo exactitud).	No presenta evaluación sobre el conjunto de prueba.
5. Comparación de modelos	Indica el tipo de validación cruzada y número de particiones. Reporta media y desviación estándar de la métrica principal. Incluye una tabla comparativa clara. Discute qué modelo es mejor, considerando rendimiento y estabilidad.	Aplica validación cruzada y compara, pero omite la desviación estándar o la tabla es incompleta. La conclusión es poco fundamentada.	Menciona la validación cruzada sin resultados numéricos o solo dice qué modelo gana sin tabla.	No realiza validación cruzada ni comparación.
6. Conclusiones y trabajo futuro	Enuncia un hallazgo principal claro, reconoce una limitación concreta del análisis y propone al menos dos mejoras específicas y viables para trabajos futuros.	Cubre dos de los tres elementos (hallazgo, limitación o mejoras) o las mejoras son demasiado vagas.	Solo menciona un elemento o es extremadamente general.	No presenta conclusiones.
7. Referencias	Incluye al menos 10 referencias en formato IEEE, todas pertinentes. Las citas están correctamente formateadas y corresponden a fuentes confiables.	Tiene entre 8 y 9 referencias, o el formato IEEE tiene errores menores, o alguna referencia no es pertinente.	Tiene entre 5 y 7 referencias, o el formato es incorrecto de manera significativa.	Menos de 5 referencias o no están en formato IEEE.
8. Estructura y claridad del reporte	Sigue la estructura solicitada. El resumen (150 palabras) sintetiza bien el proyecto. Redacción fluida en prosa, sin errores gramaticales, figuras y tablas numeradas.	Estructura correcta pero falta algún elemento (ej. resumen muy corto o ausente). Redacción clara con algunos errores menores.	Desordenado, faltan secciones importantes o la redacción es confusa con múltiples errores.	No sigue la estructura mínima.