

Universidad Veracruzana - Región Xalapa

Análisis y Clasificación de URLs para la Detección de Phishing

Aprendizaje Máquina

Abraham Nuñez Sanchez
Turan Ozbek
Rafael Alejandro Díaz Rangel

Junio 2026

I. Resumen

El presente proyecto aborda la detección automática de sitios web de phishing mediante técnicas de aprendizaje supervisado. Se utilizó el dataset “Web Page Phishing Detection”, compuesto por 11,430 URLs etiquetadas como legítimas o phishing, con 87 variables predictoras que describen características estructurales de la URL, contenido HTML y datos externos como el índice de Google, page rank y edad del dominio. El dataset se encuentra perfectamente balanceado (50% por clase), por lo que no requirió técnicas de remuestreo. Como parte del preprocesamiento se aplicó Label Encoding a la variable objetivo, una partición estratificada 70/30 para entrenamiento y prueba, y estandarización Z-score sobre las variables numéricas para el entrenamiento del modelo de Regresión Logística. Se entrenaron dos modelos de aprendizaje supervisado: Regresión Logística y Árbol de Decisión. La Regresión Logística alcanzó un accuracy de 93.96% en prueba y 93.18% en validación cruzada de 10 folds, demostrando estabilidad con una desviación estándar de 0.0038. El Árbol de Decisión obtuvo resultados similares con mayor Recall, detectando un porcentaje ligeramente superior de sitios de phishing reales. Los resultados obtenidos muestran que ambos modelos constituyen alternativas viables para la detección automatizada de URLs maliciosas, alcanzando niveles de desempeño superiores al 93% en las métricas principales de evaluación.

II. Introducción

A. Contexto

En la actualidad, Internet se ha convertido en una herramienta indispensable para la vida cotidiana de miles de millones de personas alrededor del mundo. En México, de acuerdo con datos del Instituto Nacional de Estadística y Geografía (INEGI), durante 2023 aproximadamente 97 millones de personas utilizaron Internet, lo que equivale a cerca de ocho de cada diez habitantes del país. Entre los principales usos identificados se encuentra la comunicación con otras personas mediante servicios de mensajería, correo electrónico y redes sociales.

El crecimiento constante del uso de Internet ha incrementado también la exposición de los usuarios a diversas amenazas informáticas. Por ello, resulta fundamental desarrollar mecanismos que permitan identificar y mitigar riesgos asociados al uso de servicios digitales. Una de las amenazas más comunes y peligrosas en la actualidad es el phishing.

IBM define el phishing como una técnica de ingeniería social en la que un atacante suplanta la identidad de una entidad legítima o de confianza con el objetivo de engañar a la víctima para que realice una acción determinada. Estas acciones pueden incluir el pago de facturas fraudulentas, la descarga de archivos maliciosos o el acceso a enlaces que dirigen a sitios web falsificados. Como consecuencia, los usuarios pueden revelar información sensible, comprometer sus credenciales o infectar sus dispositivos con malware.

La magnitud de esta amenaza queda reflejada en las estadísticas recientes. Según datos reportados por Statista, durante 2024 se registraron aproximadamente 38 millones de intentos de ataque relacionados con phishing, posicionándose entre los incidentes de ciberseguridad más frecuentes a nivel mundial. Asimismo, el informe “Cost of a Data Breach” de IBM indica que el phishing constituye el vector de compromiso inicial más común en las filtraciones de datos, representando aproximadamente el 15% de los incidentes analizados y generando pérdidas promedio cercanas a los 4.88 millones de dólares por organización afectada.

La efectividad de los ataques de phishing se debe, en gran medida, a la diversidad de sus objetivos y a las múltiples variantes que existen actualmente. Estos ataques pueden dirigirse tanto a usuarios individuales como a grandes empresas y organismos gubernamentales. Un caso ampliamente conocido ocurrió durante la campaña presidencial de Estados Unidos en 2016, cuando atacantes utilizaron correos electrónicos falsificados para obtener acceso a miles de mensajes pertenecientes al equipo de campaña de Hillary Clinton.

Además del phishing tradicional, existen variantes especializadas como el “Business Email Compromise” (BEC), orientado al fraude corporativo; el “spear phishing”, dirigido a individuos específicos con acceso privilegiado; y otras modalidades que utilizan distintos canales de comunicación, incluyendo correo electrónico, mensajes SMS, llamadas telefónicas y redes sociales. En muchos de estos ataques se emplean URLs maliciosas que conducen a sitios web fraudulentos diseñados para robar información o distribuir software malicioso.

Ante este panorama, las organizaciones deben combinar herramientas tecnológicas de detección de amenazas con programas de concientización y capacitación para los usuarios, con el fin de reducir el impacto de los ataques de phishing y fortalecer la seguridad de la información.

B. Objetivo

La detección automática de URLs maliciosas constituye una tarea de gran relevancia dentro del ámbito de la ciberseguridad, ya que permite:

- Reducir el riesgo de robo de credenciales e información sensible.
- Identificar sitios fraudulentos antes de que afecten a los usuarios.
- Complementar mecanismos de protección como IDS/IPS y filtros web.
- Automatizar procesos de análisis y clasificación de amenazas.

Por lo tanto, el objetivo de este proyecto es desarrollar y evaluar modelos de aprendizaje supervisado capaces de clasificar URLs como legítimas o maliciosas a partir de características extraídas de las direcciones web y de los dominios asociados.

El problema abordado corresponde a una tarea de aprendizaje supervisado de clasificación binaria, donde la variable objetivo es:

Clase	Significado
legitimate	Sitio legítimo
phishing	Sitio malicioso

III. Analisis Exploratorio de Datos - EDA

A. Descripción del conjunto de datos.

El conjunto de datos utilizado en este trabajo corresponde a “Web Page Phishing Detection”, desarrollado por Abdelhakim Hannousse y Salima Yahiouche y publicado en Mendeley Data en 2021. Quienes propusieron un conjunto de características reproducibles para la detección de sitios web de phishing mediante técnicas de aprendizaje automático. El dataset fue construido

durante mayo de 2020 con el objetivo de servir como referencia para sistemas de detección de phishing basados en aprendizaje automático.


Los autores señalan que la detección de phishing puede abordarse como un problema de clasificación supervisada y que las características utilizadas pueden agruparse en atributos basados en URL, contenido web y servicios externos. Además, los autores destacan que las características relacionadas con la URL son especialmente útiles porque permiten detectar sitios maliciosos sin necesidad de cargar completamente la página web, reduciendo riesgos y tiempos de análisis.

- Las dimensiones del conjunto de datos son:

Filas	11,430
Columnas	89

- Tipos de variables dentro del dataset:

Variables Continuas	13
Variables Enteras	74




Las variables de tipo objeto son las columnas de “URL” que es la URL original del sitio y el “status” de la URL que define si la variable es legítima o maliciosa. La mayoría de las variables son numéricas, lo cual facilita la aplicación de algoritmos de aprendizaje supervisado como árboles de decisión y regresión logística. La única variable categórica es: status que representa la clase objetivo.

- Valores faltantes


Se verificó la existencia de valores faltantes, además, se hizo una gráfica para poder visualizar si existen datos faltantes.

Total	1837
-------	------



Un total de 1837 datos, que representan el 16.07% del conjunto de datos. Los valores negativos probablemente representan dominios cuya antigüedad no pudo determinarse durante la recolección de datos. Mas adelante se mostrara cual fue el tratamiento.

- Distribucion de la variable objetivo



El conjunto de datos se encuentra perfectamente balanceado, ya que ambas clases poseen exactamente el mismo número de observaciones.

Esto es una ventaja porque:

- Evita sesgos hacia una clase dominante.
- Permite utilizar Accuracy como métrica representativa.
- Reduce la necesidad de técnicas de balanceo como sub-muestreo o sobre-muestreo.

Contiene 11,430 URLs balanceadas entre sitios legítimos y sitios de phishing, junto con 87 características extraídas de tres fuentes principales: estructura de la URL, contenido de la página web y servicios externos. La única variable categórica es la columna de “status” que muestra si una URL es legítima o maliciosa, esta columna representa la clase objetivo. Debido a su equilibrio entre clases y a la diversidad de atributos disponibles, constituye una base adecuada para la construcción y evaluación de modelos de clasificación supervisada orientados a la detección de URLs maliciosas.

IV. Preprocesamiento

El proceso de preparación de los datos se llevó a cabo en cinco etapas ordenadas para garantizar la integridad y calidad de la información antes del entrenamiento de los modelos.

A. Eliminación de columna no informativa

La columna url se eliminó porque el enfoque de este trabajo se basa exclusivamente en características previamente extraídas y cuantificadas.. Conservarla habría introducido ruido sin aportar valor predictivo al modelo.

B. Tratamiento de valores anómalos en domain_age

Durante el análisis exploratorio se identificaron valores negativos en la variable domain_age, lo cual no tiene sentido en el contexto del problema ya que la edad de un dominio no puede ser negativa. Para evitar la pérdida de observaciones, estos valores fueron reemplazados por la mediana de la variable.

C. Codificación de variables categóricas

La variable objetivo status fue transformada mediante Label Encoding, asignando el valor 0 a la clase legitimate y 1 a la clase phishing. Se eligió este método sobre One-Hot Encoding porque la variable objetivo es binaria y los modelos de clasificación supervisada requieren una representación numérica directa de la clase, no una expansión en columnas adicionales.


D. Selección de variables

El dataset contiene 89 columnas en total, de las cuales 87 corresponden a variables predictoras y 2 corresponden a las columnas url y status.

Para reducir la dimensionalidad del problema y conservar únicamente las variables con mayor capacidad discriminativa, se calculó la correlación de Pearson entre cada una de las 87 variables predictoras y la variable objetivo status. Las correlaciones se ordenaron por valor absoluto de mayor a menor, seleccionando las 15 variables con mayor correlación absoluta con la clase.

El coeficiente de correlación de Pearson toma valores entre -1 y 1, donde valores cercanos a ± 1 indican una fuerte asociación lineal con la variable objetivo, y valores cercanos a 0 indican poca o ninguna relación. Se utilizó el valor absoluto porque tanto correlaciones positivas (la variable aumenta cuando hay phishing) como negativas (la variable disminuye cuando hay phishing) son igualmente informativas para el modelo.

Se seleccionaron las 15 variables con mayor correlación absoluta, entre las que destacan `google_index` (0.731), `page_rank` (0.511), `nb_www` (0.443) y `phish_hints` (0.335). Esta estrategia permite reducir la dimensionalidad del problema conservando las variables con mayor capacidad discriminativa, eliminando variables con baja relación con la clase que podrían introducir ruido en el modelo.



E. Justificación de los modelos seleccionados

Se eligieron dos modelos supervisados diferentes:

- Árbol de Decisión
 - Puede trabajar con variables numéricas y binarias.

- No requiere normalización de los datos.
- Genera reglas fácilmente interpretables.
- Permite identificar qué variables son más importantes para la clasificación

El Árbol de Decisión fue seleccionado por su capacidad para capturar relaciones no lineales entre las variables predictoras y la clase objetivo, generando reglas de decisión fácilmente interpretables para los analistas de seguridad.

- Regresión Logística

- Es uno de los modelos de referencia para clasificación binaria.
- Produce probabilidades asociadas a cada clase.
- Funciona adecuadamente con variables numéricas.
- Permite interpretar el efecto de cada característica mediante sus coeficientes.

La Regresión Logística fue seleccionada debido a su capacidad para modelar relaciones entre múltiples variables numéricas y una variable objetivo binaria. Además, proporciona interpretabilidad mediante sus coeficientes, permitiendo identificar qué características incrementan o disminuyen la probabilidad de que una URL sea clasificada como phishing.

La utilización de ambos modelos permite comparar un enfoque basado en reglas de decisión frente a un modelo probabilístico lineal.

F. Partición entrenamiento/prueba

El conjunto de datos fue dividido en 70% para entrenamiento (8,001 registros) y 30% para prueba (3,429 registros), utilizando stratify=y para garantizar que la proporción 50/50 de clases se mantuviera en ambos subconjuntos. Sin estratificación, una partición aleatoria podría generar subconjuntos desequilibrados que afectarían la evaluación del modelo.

G. Escalado de variables numéricas

Se aplicó estandarización Z-score mediante StandardScaler, transformando cada variable para tener media 0 y desviación estándar 1. Esta técnica es necesaria para la Regresión Logística

porque dicho modelo es sensible a la escala de las variables — sin escalado, variables con rangos numéricos grandes dominarían el modelo independientemente de su importancia real. El ajuste del escalador (fit) se realizó exclusivamente sobre los datos de entrenamiento, aplicando únicamente la transformación (transform) sobre los datos de prueba, evitando así la fuga de información del conjunto de prueba hacia el modelo.

V. Entrenamiento y evaluación

Ambos modelos fueron entrenados con los datos de entrenamiento (70%) y evaluados sobre el conjunto de prueba (30%) no visto durante el ajuste.

Para la Regresión Logística se configuraron los siguientes hiperparámetros: $C=1.0$ como inverso de la fuerza de regularización, valor estándar que equilibra el ajuste a los datos de entrenamiento con la capacidad de generalización; $\text{max_iter}=500$ como límite de iteraciones, aunque el modelo convergió en solo 57 iteraciones, lo que indica que los datos escalados están bien condicionados; y $\text{solver}='lbfgs'$ como optimizador, eficiente para datasets de tamaño mediano con múltiples variables numéricas.

Para el Árbol de Decisión se establecieron: $\text{max_depth}=10$ para limitar la profundidad máxima del árbol y evitar sobreajuste; $\text{min_samples_split}=20$ como número mínimo de muestras requeridas en un nodo para que este pueda dividirse, lo que impide que el árbol cree ramas basadas en muy pocos ejemplos; y $\text{criterion}='gini'$ como medida de impureza para evaluar la calidad de cada división.

A. Métricas de evaluación

Para evaluar el rendimiento de ambos modelos se utilizaron cuatro métricas de clasificación:

- **Exactitud (Accuracy):** proporción de predicciones correctas sobre el total de ejemplos.
- **Precisión (Precision):** de todas las URLs clasificadas como phishing, qué proporción realmente lo son. Mide la tasa de falsas alarmas.

- **Sensibilidad (Recall):** de todos los sitios de phishing reales, qué proporción detectó el modelo. Es la métrica más crítica en ciberseguridad, ya que un Falso Negativo representa una amenaza no detectada que expone al usuario a riesgo real.
- **F1-Score:** media armónica entre Precisión y Sensibilidad, útil para evaluar el balance entre ambas métricas.


Adicionalmente se generó la matriz de confusión para analizar en detalle los Verdaderos Positivos, Verdaderos Negativos, Falsos Positivos y Falsos Negativos de cada modelo.

- Resultados en el conjunto de prueba


Métrica	Regresión Logística	Árbol de Decisión
Accuracy	0.9396 (93.96%)	0.9405 (94.05%)
Precision	0.9414	0.9344
Recall	0.9376	0.9475
F1-Score	0.9395	0.9409

Ambos modelos obtuvieron un rendimiento muy similar, superando el 93% en todas las métricas. La Regresión Logística obtuvo mayor Precisión (0.9414 vs 0.9344), lo que significa que genera menos falsas alarmas y clasifica menos URLs legítimas como phishing. El Árbol de Decisión obtuvo mayor Sensibilidad (0.9475 vs 0.9376), detectando un mayor porcentaje de sitios de phishing reales. Desde la perspectiva de ciberseguridad, el Recall es la métrica prioritaria, ya que un sitio de phishing no detectado representa un riesgo directo para el usuario.

B. Matriz de confusión - Regresión Logística




C. Matriz de confusión - Árbol de decisión



El modelo dejó pasar 107 sitios de phishing sin detectar (Falsos Negativos) y generó 100 falsas alarmas sobre URLs legítimas (Falsos Positivos).

D. Validación Cruzada 10-Fold

Para obtener una estimación más robusta del rendimiento, se aplicó validación cruzada con 10 folds sobre los datos de entrenamiento. Este procedimiento divide en 10 particiones. En cada iteración se utilizan 9 particiones para entrenamiento y 1 para validación, repitiendo el proceso 10 veces y promediando los resultados al final. Esto reduce el impacto de una partición afortunada o desafortunada y permite detectar sobreajuste.



El Árbol de Decisión superó la Regresión Logística en validación cruzada (0.9418 vs 0.9318), con idéntica desviación estándar de 0.0038, lo que indica que ambos modelos son igualmente

estables entre particiones. La baja desviación estándar sugiere que los modelos presentan un comportamiento estable entre diferentes particiones de los datos.

VI. Comparación de modelos

Criterio	Regresión Logística	Arbol de decision
Accuracy (prueba)	0.9396	0.9405
Precision	0.9414	0.9344
Recall	0.9376	0.9475
F1-Score	0.9395	0.9409
CV Accuracy	0.9318	0.9418
Requiere escalado	Sí	No
Tipo de frontera	Lineal	No lineal

La Regresión Logística generaliza mejor (mayor accuracy en validación cruzada) y genera menos falsas alarmas. El Árbol de Decisión detecta más phishing reales. La elección del modelo final depende de la prioridad del sistema: si se prioriza no dejar pasar amenazas, el Árbol de Decisión es preferible; si se prioriza reducir interrupciones al usuario por falsas alarmas, la Regresión Logística es la opción más adecuada.

- Regresión Logística: Se eligió como modelo principal porque el dataset contiene variables continuas (ratios y proporciones) para las cuales este modelo es naturalmente adecuado, modelando la probabilidad de pertenencia a una clase mediante la función sigmoide aplicada a una combinación lineal de las variables. Adicionalmente, es un modelo interpretable cuyos coeficientes permiten identificar la dirección e intensidad del efecto de cada variable sobre la predicción, lo cual es valioso en un contexto de ciberseguridad donde se debe justificar la decisión del sistema.
- Árbol de Decisión. Se incluyó como modelo complementario porque a diferencia de la Regresión Logística, no asume una relación lineal entre las variables y la clase objetivo. El árbol genera reglas de decisión encadenadas que pueden capturar patrones no lineales en los datos, no requiere escalado de variables y produce reglas interpretables que permiten entender exactamente qué combinación de características conduce a clasificar una URL como phishing. La comparación entre ambos modelos permite evaluar si la frontera de decisión del problema es de naturaleza lineal o no lineal.

VII. Conclusiones y trabajo futuros

Los resultados obtenidos demuestran que los modelos de aprendizaje supervisado pueden utilizarse eficazmente para la detección automática de sitios web de phishing. Tanto la Regresión Logística como el Árbol de Decisión alcanzaron niveles de exactitud superiores al 93%, evidenciando que las características extraídas de las URLs y de los dominios poseen una alta capacidad para diferenciar entre sitios legítimos y maliciosos. Aunque ambos modelos mostraron un rendimiento muy similar, el Árbol de Decisión obtuvo el mayor Recall (94.75%), mientras que la Regresión Logística presentó una mayor Precisión (94.14%). Considerando que en ciberseguridad resulta más crítico detectar amenazas reales que minimizar falsas alarmas, el Árbol de Decisión puede considerarse la alternativa más adecuada para este conjunto de datos.

Sin embargo, una limitación del presente análisis es que la detección se basa exclusivamente en características técnicas del sitio web y en un conjunto de datos recopilado en un periodo específico. El phishing es una amenaza en constante evolución y, debido a que explota

principalmente factores humanos mediante técnicas de ingeniería social, no siempre puede ser detectado únicamente mediante mecanismos automáticos.

Como trabajo futuro, se propone evaluar modelos más avanzados para analizar si es posible incrementar el rendimiento de detección. Asimismo, sería conveniente incorporar conjuntos de datos más recientes que reflejen nuevas estrategias utilizadas por los atacantes y realizar pruebas con datos obtenidos en entornos reales. Finalmente, una línea de investigación interesante consiste en combinar la detección basada en aprendizaje automático con mecanismos de concientización para usuarios y sistemas de monitoreo en tiempo real, creando así una estrategia de defensa más integral frente a los ataques de phishing.

VIII. Referencias

1. INEGI. “Usuarías y usuarios de internet”. Cuéntame de México. Accedido el 6 de junio de 2026. [En línea]. Disponible:
https://cuentame.inegi.org.mx/descubre/poblacion/usuarios_de_internet/
2. Statista Research Department. “Phishing”. Statista. Accedido el 6 de junio de 2026. [En línea]. Disponible: <https://www.statista.com/topics/8385/phishing/#topicOverview>
3. M. Kosinski. “¿Qué es el phishing? | IBM”. IBM. Accedido el 6 de junio de 2026. [En línea]. Disponible: <https://www.ibm.com/mx-es/think/topics/phishing>
4. Colaboradores de Wikipedia. “Correos electrónicos de Podesta - Wikipedia, la enciclopedia libre”. Wikipedia, la enciclopedia libre. Accedido el 7 de junio de 2026. [En línea]. Disponible: https://es.wikipedia.org/wiki/Correos_electrónicos_de_Podesta
5. A. Hannousse y S. Yahiouche. “Web page phishing detection”. Mendeley Data. Accedido el 7 de junio de 2026. [En línea]. Disponible:
<https://data.mendeley.com/datasets/c2gw7fy2j4/3>