

Notas Aprendizajemaquina

Abraham Nuñez

April 15, 2026

Contents

1	Informacion	2
2	Informacion	2
2.1	Evaluacion	2
3	Temario	2
4	Introduccion	2
4.1	Inteligencia Artificial	2
4.1.1	Cognicion y comportamiento	3
4.2	Tipos de sistemas	3
4.3	Simulacion del comportamiento humano	3
4.4	Aprendizaje Maquina	4
4.4.1	Tipos de aprendizajes	4
4.5	Introduccion al manejo de datos	4
4.5.1	Datos estructurados	5
4.5.2	Datos NO estructurados	5
4.5.3	Datos etiquetados	5
4.5.4	Datos NO etiquetados	6
4.5.5	Repositorio de datos	6
4.5.6	Formatos de datos de texto	6
4.5.7	Limpieza y procesamiento de datos	6
4.5.8	Python para el aprendizaje maquina	7
4.6	Técnicas de codificación	7
4.6.1	Tecnicas comunes:	7
4.7	Aprendizaje supervisado	8
4.7.1	Flujo de aprendizaje supervisado	8

1 Informacion

- Maestro: David Martinez Galicia
- Materia: Aprendizaje Maquina
- Carrera: CIberseguridad e Infraestructura de Computo
- Contacto: davidmartinez02@uv.mx

2 Informacion

2.1 Evaluacion

- Exámenes: 40%
- Tareas: 30%
- Proyecto: 30%

3 Temario

- 1. Introduccion
- 2. Manejo de datos
- 3. Aprendizaje supervisado
- 4. Aprendizaje no supervisado
- 5. Aprendizaje por refuerzo
- 6. Evaluacion de modelos

4 Introduccion

4.1 Inteligencia Artificial

- Que es la inteligencia artificial?
- “Cada aspecto de la inteligencia artificial puede ser descrito con suficiente precision que puede fabricarse una maquina para simularlo”.
- El concepto existe desde 1956.

- Inteligencia artificial: Un enfoque moderno, Pearson Russell, S. J., y Norving P. (2021).
- Concuerdan que la IA debe estudiar sistemas inteligentes.
- Características para ser inteligentes:

4.1.1 Cognición y comportamiento

- Pensar (crear) -> Humano
- Actuar (simular) -> Racional

4.2 Tipos de sistemas

- Sistemas que piensan como humanos
- Sistemas que piensan racionalmente
- Sistemas que actúan como humanos
- Sistemas que actúan racionalmente

4.3 Simulación del comportamiento humano

- La prueba de Turing
- El sistema debe de poseer las siguientes capacidades:
 - Procesamiento de lenguaje natural
 - Representación del conocimiento
 - Razonamiento automático
 - Aprendizaje máquina
- Para superar la prueba de Turing la computadora debe incluir:
 - Visión computacional para percibir objetos.
 - Robótica para manipular y mover objetos.

4.4 Aprendizaje Maquina

- Se refiere a un espectro de situaciones en las cuales un agente incrementa su conocimiento para cumplir una tarea.
- Machine Learning. Mitchell, T. M. (1997).
- Un programa de computadora aprende de la experiencia E, con respecto a alguna clase de tareas T y una medida de desempeno P, si su desempeno en las tareas T, medido por P, mejora con la experiencia E.

4.4.1 Tipos de aprendizajes

- Aprendizaje supervisado: Aprender una funcion a partir de ejemplos de sus entradas y sus salidas.
 - Clasificacion: Diagnostico de enfermedades.
 - Regresion: Prediccion de la temperatura.
- Aprendizaje no supervisado: Aprender a partir de patrones de entradas que no tienen valores de salidas.
 - Agrupacion: Segmentacion de clientes.
 - Reduccion de dimensionalidad: Visualizar datos.
 - Estimacion de la densidad: Describir la altura de una poblacion.
- Aprendizaje por refuerzo: Aprender una forma de actuar usando un refuerzo (recompens o penalizacion)
 - Aprender politicas de accion: Actuar en un entorno.

4.5 Introduccion al manejo de datos

- La calidad de los datos determina la calidad del modelo.
- “Garbage in, garbage out”.
- Sin la preparacion adecuada de los datos, no hay aprendizaje efectivo.
- Transformamos datos crudos en patrones para la toma de decisiones.
- Datos limpios dectetan amenazas reales en ciberseguridad.

4.5.1 Datos estructurados

- Datos organizados en formato tabular con esquema definido.

1. Características:

- Formate predecible.
- Tipos de datos definidos.
- Fáciles de almacenar y consultar en bases de datos relacionales.
- Ejemplos:
 - Tablas SQL.
 - Hojas de cálculo Excel/CSV.
 - Logs de sistemas con formatos fijos.

4.5.2 Datos NO estructurados

- Datos sin formato predefinido ni organización tabular.

1. Características:

- Sin esquema fijo.
- Requieren procedimiento previo para extraer información.
- Representan 80% de los datos empresariales,
- Ejemplos:
 - Texto.
 - Imágenes y videos.
 - Audio y grabaciones.

4.5.3 Datos etiquetados

- Conjunto de datos donde cada ejemplo tiene una etiqueta/clase asociada.

1. Características:

- Requieren proceso manual o semi-automático de etiquetado.
- Esenciales para entrenar modelos supervisados.
- Costosos de obtener y validar.
- Ejemplos:
 - Correos spam/no spam
 - Imágenes de rostros con nombre de persona

4.5.4 Datos NO etiquetados

- Datos sin categorias o respuestas conocidas.

1. Caracteristicas:

- Abundantes y faciles de recolectar.
- Requieren tecnicas de descubrimiento de patrones.
- Utiles para deteccion de anomalias.
- Ejemplos:
 - Trafico de red
 - Comportamiento de usuario
 - Codigo malicioso

4.5.5 Repositorio de datos

4.5.6 Formatos de datos de texto

- Los formatos de texto permiten almacenar y procesar datos eficientemente.
- Son los mas comunes para cargar en la mayoria de las herramientas

1. Tipos de datos de texto

- CVS: Formato tabular simple y universalmente compatible.
- TSV: Similar al CSV, pero con tabulaciones como delimitador.
- JSON: Ligero y flexible para datos estructurados y anidados.
- XML: Formato estructurado y autodescriptivo, aunque verboso.
- ARFF: Incluye metadatos, usado comunmente en Weka.
- Texto plano: Sin formato, para datos sin estructura o documentos.

4.5.7 Limpieza y procesamiento de datos

- Los datos del mundo real son inexactos, inconsistentes e incompletos.
- El procesamiento de datos asegura la integridad de los datos.
- Permite generar analisis confiables y conclusiones validas.

- Evita decisiones incorrectas o modelos ineficaces.

1. Flujo de trabajo de limpieza y preprocesamiento

- Recopilacion: Obtener datos de bases de datos, APIs o scraping.
- Limpieza: Corregir errores, eliminar duplicados y manejar valores faltantes.
- Integracion: Unir datos de multiples fuentes, resolviendo inconsistencias.
- Transformacion: Codificar, normalizar y crear nuevas variables.
- Reduccion: Seleccionar caracteristicas para simplificar el analisis.

4.5.8 Python para el aprendizaje maquina

- Lenguaje preferido por su facilidad y bibliotecas especializados.

1. Bibliotecas importantes

- Pandas: Manipulacion de datos.
- Numpy: Calculos numericos.
- SciPy: Computo cientifico, estadistica y senales.
- Matplotlib/Seaborn: Visualizacion de datos.
- Scikit-learn: Machine learning y preprocesamiento.

4.6 Técnicas de codificación

- Las variables categóricas representan grupos categóricas.
- Algunos modelos de aprendizaje maquina requieren entradas numéricas.
- Transformar categorías en números para análisis y modelado.

4.6.1 Tecnicas comunes:

- One-Hot Encoding: Para categorías sin orden (ej: puerto de embarque).
- Label Encoding: Para categorías con orden (ej: nivel educativo).
- Puntuación Z: Es una medida estadistica que indica cuantas desviaciones estandar se encuentra por encima o por debajo de la medida de una distribución.

4.7 Aprendizaje supervisado

- Los humanos aprendemos de experiencias pasadas.
- Un niño aprende a identificar animales viendo ejemplos.
- La experiencia se acumula y permite generalizar.
- Una computadora no tiene experiencias. En su lugar, aprende de datos.
- Estos datos son ejemplos históricos con entradas y salidas conocidas.
- El objetivo es obtener una función que prediga salidas para nuevas entradas.

4.7.1 Flujo de aprendizaje supervisado

- Para generar un modelo se necesita un conjunto de datos, un algoritmo de aprendizaje y una forma de evaluarlo o interpretarlo.
 - Conjunto de datos
 - Modelo supervisado: Existen más de cientos cincuenta modelos clasificadores:
 - * Regresión lineal.
 - * Redes neuronales.
 - * Redes bayesianas.
 - * Árboles de decisión.
 - Interpretación/Evaluación: Una vez obtenido el modelo, se puede:
 - * Analizar el conocimiento o los patrones capturados.
 - * Medir su desempeño en datos no observados antes.

1. Datos en el aprendizaje supervisado

- Un conjunto de datos compuesto por:
 - Una lista de registros (observaciones o ejemplos)
 - Un conjunto de variables predictorias (características o atributos)
 - * Las variables cuantitativas se conocen como continuas o numéricas.

- * Las variables cualitativas se conocen como discretas o categoricas.
- * Dentro de las categorias (cualitativas) existen las nominales y las ordinales.
- Una variable por predecir (dependiente, objetivo o clase).
- Si la variable objetivo es categorica se vuelve un problema de clasificacion.
- Si la variable objetivo es numerica se vuelve un problema de regresion.

2. Modelos supervisados de aprendizaje

- Un modelo es una funcion o teoria que se aprenda de los datos.
- Puede verse como una hipotesis sobre la relacion entre entradas y salidas.
- Se ajusta (entrena) un modelo usando un algoritmo de aprendizaje.
- El algoritmo (metodo o tecnica) encuentra los **parametros** del modelo.
- Los algoritmos se configuran a traves de sus **hiperparametros**.
- Una vez entrenado, el modelo puede predecir salidas para nuevos datos.
- Si la variable objetivo es categorica, el modelo se llama **clasificador**.
- Si la variable objetivo es numerica, el modelo se llama de **regresion**.

3. Interpretacion y evaluacion de modelos.

- Los modelos no solo predicen, tambien representan conocimiento.
- Ese conocimiento revela patrones sobre como se relacionan las variables.
- Es importante para tomar decisiones en situaciones complejas.
- Algunos modelos permiten interpretar ese conocimiento.
- Los modelos que no se pueden interpretar se denominan de caja negra.
- Evaluar un modelo es tan importante como entrenarlo.

- La evaluacion determina si el modelo es confiable o debe sustituirse.

4. Modelo de regresion lineal

- Describe la relacion entre la variable independiente y una dependiente.
- Asume que dicha relacion puede representarse mediante una linea recta.
- Permite predecir valores continuos a partir de un solo atributo.
- Es el puntaje de partida para entender las tareas de regresion.
- $y = mx + b$ (Funcion de una recta).
- $y = O(0) + O(1)x$
 - y : valor predicho por el modelo
 - x : variable independiente
 - $O(0)$: intercepto que representa el valor de y cuando $x = 0$
 - $O(1)$: pendiente que representa el cambio en y por cada unidad en x .
- El objetivo del modelo es que y sea lo mas cercano posible a y .
- El modelo define una familia de todas las lineas posibles.
- Los parametros $\theta = [O(0), O(1)]^T$ determinen la linea especifica.
- Funcion de perdida (Loss Function): Mide que tan mal se ajusta el modelo a los datos.
 - Para cada punto, calculamos el error: diferencia entre el valor real y predicho.
 - Se usa el error cuadratico para que la direccion no importe.
 - La perdida total es la suma de errores cuadraticos (SSE).

Agregar una imagen con la formula